AlignmentGraph-ISD: Hệ đa tác tử thiết kế giảng dạy có thể kiểm toán trên mô hình ngôn ngữ nhỏ

Bùi Việt Phương[1], Bùi Văn Tâm[2], Phạm Văn Hải[1,*]
[1]Trường Công nghệ Thông tin và Truyền thông, Đại học Bách khoa Hà Nội
[2]Khoa Công nghệ Thông tin, Trường Đại học Hải Phòng
Email: phuong.bv242011m@sis.hust.edu.vn, tambv@dhhp.edu.vn, haipv@soict.hust.edu.vn
[*]Tác giả liên hệ

***Tóm tắt*—Các hệ tác tử dựa trên mô hình ngôn ngữ lớn (LLM) cho thiết kế giảng dạy (ISD) phần lớn dựa vào LLM thương mại gọi qua API, trong khi các cơ sở giáo dục cần mô hình ngôn ngữ nhỏ (SLM) vận hành tại chỗ. Với SLM, sự căn chỉnh giữa mục tiêu, hoạt động và đánh giá có nguy cơ bị phá vỡ mà LLM judge không chỉ ra được. Bài báo đề xuất AlignmentGraph-ISD, một hệ đa tác tử phân rã theo vai dùng chung một đồ thị căn chỉnh. Khung điều phối ghi và kiểm tra các quan hệ căn chỉnh, rồi xuất đồ thị cùng sổ vi phạm để kiểm toán. Trên 30 kịch bản của ISD-Agent-Bench với Qwen3.5-2B, tuy điểm ADDIE của hệ (59.0) không khác biệt có ý nghĩa với tác tử mạnh nhất của benchmark là React-ADDIE (59.1), song ba tín hiệu tương ứng văn bản, đo không dùng LLM, của hệ cao hơn cả sáu hệ đối chứng. Thí nghiệm phân tích thành phần cho thấy việc phân rã thành nhiều tác tử theo vai nâng điểm ADDIE thêm 4.9 điểm so với một tác tử duy nhất ($p < 0.001$). Trong khi đó, việc thay blackboard dạng văn bản bằng đồ thị căn chỉnh không cho thấy khác biệt có ý nghĩa về tỉ lệ mục tiêu được liên kết đầy đủ với cả hoạt động lẫn đánh giá, mà chủ yếu bổ sung khả năng kiểm toán.**

***Từ khóa*—hệ đa tác tử (multi-agent system); mô hình ngôn ngữ nhỏ (small language model); thiết kế giảng dạy (instructional design); căn chỉnh kiến tạo (constructive alignment); đồ thị căn chỉnh (alignment graph)**

I. GIỚI THIỆU

Thiết kế giảng dạy (Instructional Systems Design – ISD) là quá trình xây dựng một khóa học, từ phân tích nhu cầu đến kế hoạch triển khai. Mô hình ADDIE tổ chức quá trình này thành năm pha: phân tích, thiết kế, phát triển, triển khai và đánh giá [1]. Các hệ tác tử dựa trên mô hình ngôn ngữ lớn (Large Language Model – LLM) có thể đảm nhận gần trọn quy trình ISD. Các hệ này sinh kế hoạch bài giảng, bộ công cụ đánh giá và gói học liệu từ một bản mô tả yêu cầu thiết kế [2]–[4]. Bộ đánh giá chuẩn (benchmark) ISD-Agent-Bench so sánh các hệ này trên một tập kịch bản chung, với LLM đóng vai giám khảo (LLM judge) chấm theo bộ tiêu chí (rubric) [5].

Tuy nhiên, các hệ tác tử ISD nói trên đều được xây dựng và kiểm chứng trên LLM thương mại gọi qua API. Trong khi đó, hạn chế tài chính đang làm chậm việc ứng dụng trí tuệ nhân tạo ở các trường đại học [6]. Dữ liệu người học cũng phải đi qua hạ tầng của bên thứ ba, gây lo ngại về quyền riêng tư [7]. Vì vậy, các cơ sở giáo dục quan tâm đến mô hình ngôn ngữ nhỏ (Small Language Model – SLM) mã nguồn mở, vận hành tại chỗ (on-premise) [8], [9].

Khi kích thước mô hình giảm, chất lượng đầu ra phụ thuộc nhiều hơn vào khung điều phối (harness) bao quanh mô hình. Phân rã bài toán cho một hệ đa tác tử (Multi-Agent System – MAS) là một hướng đã có bằng chứng thực nghiệm. Khung đa tác tử phân rã giúp SLM sử dụng công cụ tốt hơn [10]. Một hướng khác là chưng cất quỹ đạo tác tử (agent distillation), giúp các mô hình 0.5B–3B đạt kết quả gần với mô hình lớn hơn [11]. Tuy nhiên, tác dụng của khung điều phối có thể không đơn điệu theo năng lực mô hình [12], nên cần đo trực tiếp lợi ích này.

Đối với ISD, yêu cầu cốt lõi mà hệ thống phải bảo đảm là sự căn chỉnh. Theo lý thuyết căn chỉnh kiến tạo (constructive alignment), chất lượng thiết kế nằm ở quan hệ giữa mục tiêu học tập, hoạt động dạy–học và đánh giá, chứ không nằm ở từng thành phần riêng lẻ [13]. Trong các hệ tác tử hiện có, các quan hệ này chỉ tồn tại ngầm trong văn bản truyền giữa các bước. Vì vậy, sự nhất quán của thiết kế phụ thuộc vào khả năng mô hình giữ cho một chuỗi sinh dài không tự mâu thuẫn, và khả năng này có thể suy giảm khi mô hình nhỏ đi. Mặt khác, LLM judge có các thiên lệch đã được ghi nhận [14], và một bản thiết kế viết trôi chảy vẫn có thể đạt điểm cao trong khi các quan hệ căn chỉnh bên dưới đã bị phá vỡ.

Từ các phân tích trên, có thể thấy còn thiếu một hệ tác tử ISD giữ quan hệ căn chỉnh như một trạng thái tường minh, kiểm tra được ngay trong lúc sinh và được đánh giá với SLM vận hành tại chỗ. Vì vậy, đóng góp của bài báo này là AlignmentGraph-ISD, một MAS phân rã theo vai cho ISD. Các tác tử dùng chung một đồ thị căn chỉnh, trong đó mỗi quan hệ mục tiêu–hoạt động–đánh giá là một cạnh có kiểu do khung điều phối ghi khi tác tử nộp sản phẩm. Đồ thị và sổ vi phạm (violation ledger) được xuất ra để người thiết kế giảng dạy truy vết. Trên ISD-Agent-Bench với Qwen3.5-2B, tuy điểm LLM judge của hệ không khác biệt có ý nghĩa với tác tử mạnh nhất của benchmark, song các tín hiệu tương ứng văn bản của hệ cao hơn mọi hệ đối chứng, và hệ cung cấp thêm hồ sơ kiểm toán, đổi lại chi phí token cao hơn. Thí nghiệm phân tích thành phần cho thấy lợi ích đo được đi cùng việc phân rã theo vai; đồ thị không cho thấy khác biệt có ý nghĩa

so với blackboard dạng văn bản.

Phần II–V lần lượt trình bày nghiên cứu liên quan, hệ thống đề xuất, thực nghiệm và kết luận.

II. CÁC NGHIÊN CỨU LIÊN QUAN

A. Hệ LLM và hệ tác tử cho thiết kế giảng dạy

COMA dùng ba tác tử theo vai lần lượt tinh chỉnh kế hoạch bài giảng [2]. EduPlanner dùng nhiều tác tử LLM lần lượt đánh giá và chỉnh sửa thiết kế bài giảng [3]. Instructional Agents sinh trọn gói học liệu của một khóa học bằng các tác tử theo vai [4]. ISD-Agent-Bench tập hợp các tác tử theo nhiều lý thuyết ISD, trong đó có một tác tử theo mẫu ReAct [5], [15]. Các hệ này chạy trên mô hình thương mại mạnh và giữ sự nhất quán giữa các thành phần một cách ngầm định. Về kiến trúc, EduPlanner, Instructional Agents và hệ đề xuất cùng thuộc nhóm MAS theo quy trình vận hành chuẩn (Standard Operating Procedure – SOP) như MetaGPT [16], [17]. Trong nhóm này, các vai và thứ tự của chúng được định trước. Điểm khác biệt nằm ở đối tượng mà các tác tử dùng chung: văn bản truyền giữa các bước, hoặc một trạng thái có thể truy vấn và kiểm toán.

B. SLM và mô hình tại chỗ trong giáo dục

Chan và cộng sự so sánh các cỡ mô hình vận hành tại chỗ cho trường học [8]. Katharakis và cộng sự cho thấy SLM 7–17B chạy trên một máy chủ GPU có thể làm trợ giảng theo chương trình học [9]. Tuy nhiên, mỗi nghiên cứu trên chỉ xử lý một phần của quy trình ISD. Chưa nghiên cứu nào trong số đó đánh giá một MAS bao quát trọn quy trình ISD trên SLM.

C. Căn chỉnh kiến tạo và đánh giá bằng LLM judge

Căn chỉnh kiến tạo yêu cầu mục tiêu học tập, hoạt động dạy–học và nhiệm vụ đánh giá cùng hướng về một kết quả học tập dự kiến [13]. Khi dùng ChatGPT thiết kế khóa học theo căn chỉnh kiến tạo, kết quả vẫn cần giảng viên hoàn thiện [18]. Thang phân loại Bloom sửa đổi cung cấp bộ từ vựng chung về mức nhận thức [19]. Ở phía đánh giá hệ thống, LLM judge có các thiên lệch đã biết như thiên lệch vị trí, độ dài và tự ưu tiên [14]. Khi chấm từng pha ADDIE riêng rẽ, LLM judge cũng không thấy liên kết giữa các thành phần thuộc những pha khác nhau.

III. HỆ THỐNG ĐỀ XUẤT

A. Kiến trúc tổng thể

AlignmentGraph-ISD nhận một bản mô tả yêu cầu thiết kế (design brief) và trả về một bản thiết kế khóa học theo cấu trúc ADDIE. Hình 1 trình bày kiến trúc của hệ, gồm đồ thị căn chỉnh (alignment graph) dùng chung, sáu tác tử giai đoạn (Stage Agent) và khung điều phối tất định. Mô hình chỉ viết nội dung giảng dạy. Khung điều phối quyết định thứ tự các giai đoạn, định dạng bắt buộc của từng sản phẩm, việc ghi đồ thị, việc kiểm tra và việc báo cáo.

Mỗi giai đoạn do một Stage Agent có vai riêng đảm nhận. (1) *Phân tích nhu cầu* (Needs Analyst Agent): khoảng trống năng lực, hồ sơ người học, chủ đề và ràng buộc. (2) *Mục tiêu và mô-đun* (Outcome Designer Agent): mục tiêu học tập và các mô-đun; mỗi mô-đun gom một số mục tiêu và chủ đề, kèm thời lượng. (3) *Đánh giá* (Assessment Designer Agent): kế hoạch đánh giá với bảng đặc tả (blueprint) các nhiệm vụ đánh giá theo mô-đun; mỗi nhiệm vụ có thời điểm (chẩn đoán, quá trình hoặc tổng kết), hình thức và quy mô. (4) *Hoạt động* (Activity Designer Agent): chiến lược dạy học. (5) *Học liệu* (Content Designer Agent): lựa chọn phương tiện. (6) *Triển khai* (Implementation Planner Agent): sáu sản phẩm gồm tập huấn giảng viên, kiểm tra hệ thống, chạy thử, giám sát, tài liệu hướng dẫn giảng viên và tài liệu hướng dẫn vận hành.

Thứ tự trên tuân theo thiết kế ngược (Backward Design): xác định kết quả mong muốn trước, sau đó đến bằng chứng đánh giá và cuối cùng là kế hoạch học tập [20]. Thứ tự này được chỉ thị trong prompt và cố định. Tác tử tự chủ trong cách thực hiện một giai đoạn nhưng không chọn giai đoạn kế tiếp. Vì vậy, hệ là một MAS phân rã theo vai kiểu quy trình (workflow-style). Hệ điều phối tĩnh, không có thương lượng và không lập kế hoạch động giữa các vai [16]. Hệ không có giai đoạn riêng cho pha Evaluation của ADDIE. ADDIE là cấu trúc của đầu ra: bộ tổng hợp (aggregator) sắp xếp nội dung từ đồ thị thành năm pha theo định dạng mà benchmark yêu cầu.

B. Đồ thị căn chỉnh

Trạng thái dùng chung là một đồ thị có hướng

$$G = (V, E), \qquad E \subseteq V \times V \times \mathcal{R}. \tag{1}$$

Mỗi nút $v \in V$ là một sản phẩm thiết kế có kiểu, như khoảng trống năng lực, chủ đề, ràng buộc, hồ sơ người học, mục tiêu, mô-đun, nhiệm vụ đánh giá, hoạt động, học liệu hay hướng dẫn buổi học. Mỗi cạnh (u, v, r) nối hai sản phẩm qua một quan hệ r thuộc tập $\mathcal{R}$ gồm 17 kiểu quan hệ. Ký hiệu $E_r = \{(u, v) \colon (u, v, r) \in E\}$. Ba quan hệ cốt lõi (giữ cách đánh số trong mã nguồn) là ba cạnh của tam giác căn chỉnh kiến tạo: C_2 (`assessed_by`) nối mục tiêu với nhiệm vụ đánh giá đo nó, C_3 (`practiced_by`) nối mục tiêu với hoạt động luyện tập nó, và C_4 (`prepares_for`) nối hoạt động với nhiệm vụ đánh giá mà nó chuẩn bị. Mười bốn quan hệ phụ P_1–P_{14} ghi nguồn gốc, cách tổ chức theo mô-đun và việc truy vết khi triển khai. Mô-đun chỉ tham gia quan hệ phụ, vì mô-đun là đơn vị tổ chức khóa học, không phải một đỉnh của tam giác.

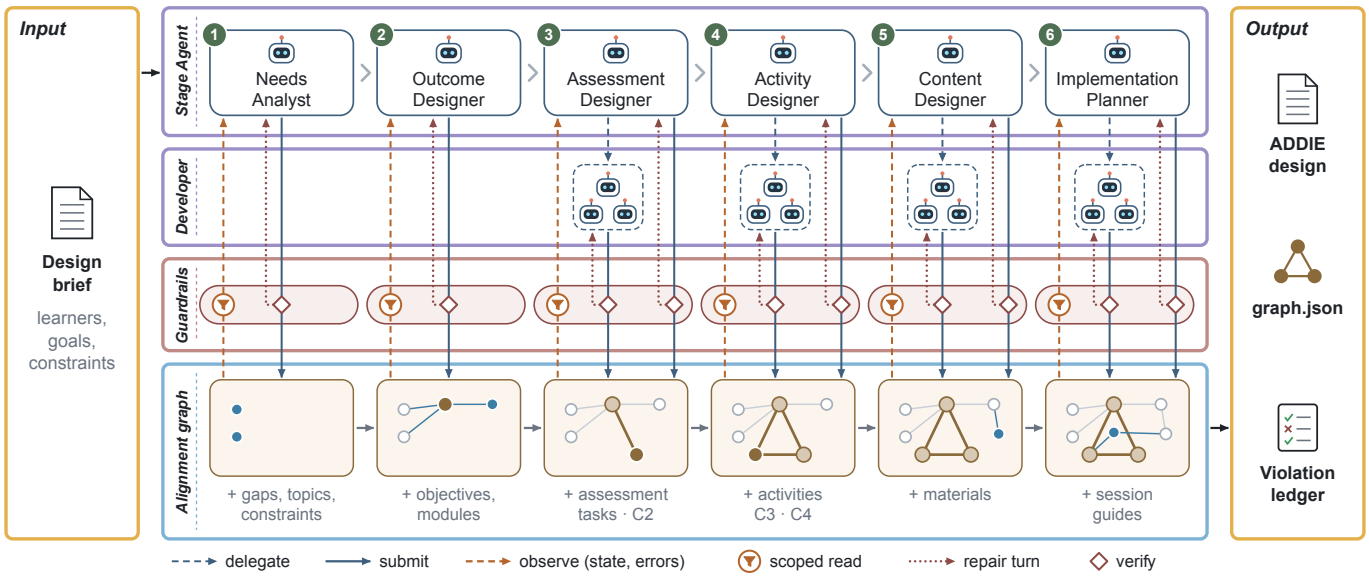
Một mục tiêu o được căn chỉnh về cấu trúc khi tam giác khép kín trên nó:

$$\begin{aligned}\text{aligned}(o) \iff \exists\, h, d \colon\ & (o, h) \in E_{C_3} \wedge (o, d) \in E_{C_2} \\ & \wedge\, (h, d) \in E_{C_4},\end{aligned} \tag{2}$$

trong đó h là một hoạt động và d là một nhiệm vụ đánh giá. Ba cạnh phải gặp nhau trên cùng một hoạt động và cùng một nhiệm vụ. Nếu ba cạnh chỉ tồn tại riêng rẽ thì chưa đủ, vì hoạt động có thể chuẩn bị cho một nhiệm vụ không đo o.

Với mỗi quan hệ r, gọi S_r là tập nút được xét độ phủ (coverage side) của r và $N_r(v)$ là tập nút nối với v qua r theo hướng đó. Độ phủ của r là

$$\text{cov}(r) = \frac{\left|\{v \in S_r \colon N_r(v) \neq \emptyset\}\right|}{|S_r|}. \tag{3}$$



Hình 1. Kiến trúc AlignmentGraph-ISD. Sáu Stage Agent lần lượt làm việc theo thứ tự 1–6; ở bốn giai đoạn, Developer thực hiện các nhóm việc được suy ra từ sản phẩm của Stage Agent. Mọi lượt đọc và nộp đi qua lớp kiểm soát (guardrails) của khung điều phối: lượt đọc chỉ trả về phạm vi của vai; lượt nộp đạt kiểm tra thì được ghi vào đồ thị, không đạt thì lỗi được trả lại cho tác tử đã nộp để sửa. Hàng dưới cùng là đồ thị sau từng giai đoạn; tam giác C2–C4 khép lại ở giai đoạn 4.

Ví dụ, $\mathrm{cov}(C_2)$ là tỉ lệ mục tiêu có ít nhất một nhiệm vụ đánh giá đo nó. Điều kiện (2) và độ phủ (3) là đại lượng cấu trúc: chúng cho biết quan hệ có tồn tại hay không, không cho biết thiết kế có giá trị sư phạm hay không.

Mô hình không trực tiếp tạo cạnh. Mỗi sản phẩm khai báo mã định danh (id) của các sản phẩm mà nó phục vụ, ví dụ một hoạt động khai báo mục tiêu mà nó luyện tập. Khi ghi sản phẩm, khung điều phối tra từng id và tự ghi cạnh có kiểu. Vì vậy, quan hệ hình thành đúng tại thời điểm ghi. Một id không trỏ tới nút nào thì không tạo cạnh. Phần thiếu hụt này được phản ánh trong độ phủ.

C. Vòng lặp act–observe của một tác tử

Mỗi tác tử chạy một vòng lặp hành động–quan sát (act–observe) theo mẫu ReAct [15], dùng cơ chế gọi công cụ (tool calling) gốc của mô hình. Công cụ `read_alignment_state` không có tham số và trả về lát cắt đồ thị theo vai của tác tử: những gì đã có kèm id, phần do tác tử viết, những gì còn thiếu mà tác tử phải bổ sung, và các vi phạm đang mở của nó. Công cụ `read_node` trả về trọn một sản phẩm. Mỗi sản phẩm có một công cụ nộp riêng `submit_<sản phẩm>`, và sản phẩm chính là tham số của lời gọi nộp.

Khung điều phối kiểm tra mỗi lần nộp bằng bộ kiểm tra hợp lệ (validator) của sản phẩm. Lần nộp hợp lệ được ghi thành nút có kiểu kèm các cạnh như ở Mục III-B. Lần nộp không hợp lệ bị từ chối, và thông báo lỗi của validator trở thành quan sát kế tiếp để tác tử sửa và nộp lại. Mỗi sản phẩm được phép tối đa ba lần nộp không tiến triển. Mỗi giai đoạn có trần số lượt. Nếu một giai đoạn không hoàn tất trong các giới hạn này, khung điều phối vẫn ghi phần tốt nhất mà mô hình đã viết, đánh dấu giai đoạn là bỏ dở (`gave_up`) và ghi nhận điều này trong kết quả.

Có bốn loại sản phẩm mà số lượng tăng theo quy mô thiết kế: câu hỏi đánh giá (nằm trong nhiệm vụ đánh giá), hoạt động học tập, học liệu và hướng dẫn buổi học. Các loại này do tầng tác tử phát triển (Developer) viết, mỗi Developer đảm nhận một nhóm việc (work set). Nhóm việc được suy ra từ thiết kế đã có: mỗi mô-đun là một nhóm, riêng phần đánh giá thì mỗi mục của bảng đặc tả là một nhóm. Mô hình không tự chọn cách chia nhóm. Developer chạy cùng kiểu vòng lặp act–observe và ghi vào cùng đồ thị. Nếu sau đó vẫn còn phần thiếu hụt, khung điều phối giao lại nhóm việc liên quan cho Developer, tối đa một lần, kèm danh sách những gì còn thiếu.

D. Kiểm tra, sửa và sổ vi phạm

Sau mỗi giai đoạn, khung điều phối chạy các phép kiểm tra tất định gắn với giai đoạn đó mà không gọi mô hình. Các phép kiểm tra gồm sự khớp giữa động từ Bloom và mức khai báo, tính đo được của mục tiêu, độ phủ quan hệ, bảng đặc tả, câu hỏi, ngân sách thời gian, lịch triển khai và tính khả thi.

Việc sửa có hai tầng. Tầng thứ nhất là sửa cấu trúc do khung điều phối thực hiện mà không gọi mô hình. Tầng này chỉ sắp xếp lại những gì thiết kế đã có, ví dụ trỏ lại một tham chiếu không hợp lệ hoặc thay động từ ngoài thang Bloom bằng động từ mà mức khai báo cho phép. Tầng thứ hai dành cho vi phạm cần viết thêm nội dung. Vi phạm loại này được chuyển cho tác tử phụ trách dưới dạng một yêu cầu sửa, ngay trong hội thoại của tác tử đó. Tác tử đọc lại trạng thái, thấy vi phạm đang mở và nộp lại. Khung điều phối không tự viết nội dung giảng dạy. Với một số loại vi phạm, khung điều phối không sửa mà chỉ ghi nhận và thống kê nếu vi phạm vẫn còn.

Mỗi vi phạm được ghi vào sổ vi phạm cùng kết cục: còn mở, do khung điều phối sửa hoặc do tác tử sửa. Với vi phạm còn mở, sổ ghi lý do: tác tử đã thấy nhưng không sửa được,

hết ngân sách, không có tác tử nào phụ trách, hoặc chưa được đưa tới tác tử nào. Sau sáu giai đoạn, một lượt đối chiếu (reconciliation) tất định gán các vi phạm liên giai đoạn còn lại cho tác tử phụ trách và chỉ sửa cấu trúc, không gọi mô hình. Bộ tổng hợp dựng bản thiết kế ADDIE hoàn chỉnh từ đồ thị. Cuối cùng, bộ kiểm toán (auditor) ghi lại các vi phạm chưa được xử lý.

Mỗi lần chạy xuất ra hai tệp. Tệp `graph.json` chứa mọi nút, cạnh có kiểu và các cạnh tam giác của từng mục tiêu. Tệp `violations.json` chứa sổ vi phạm. Người thiết kế giảng dạy có thể truy vết từng quan hệ mục tiêu–hoạt động–đánh giá và can thiệp khi cần, theo nguyên tắc giảng viên trong vòng lặp (teacher-in-the-loop). Như vậy, cơ chế kiểm tra–sửa đóng vai trò sửa dự phòng và cung cấp bằng chứng kiểm toán.

IV. THỰC NGHIỆM VÀ ĐÁNH GIÁ

A. Thiết lập thực nghiệm

1) Dữ liệu và mô hình: Chúng tôi dùng 30 kịch bản thuộc tập kiểm tra của ISD-Agent-Bench [5]. Tập này tách biệt với 10 kịch bản đã dùng trong giai đoạn hoàn thiện hệ. Mọi hệ chạy trên cùng mô hình Qwen3.5-2B, vận hành tại chỗ bằng vLLM, với nhiệt độ sinh mặc định 0.7 (EduPlanner giữ nhiệt độ riêng cho từng vai theo thiết kế gốc) và cùng trần 8192 token cho mỗi lượt gọi. Trần này là mức mà một GPU 12–16 GB còn đáp ứng được khi chạy mô hình đến 4B, tức môi trường triển khai mà bài báo nhắm tới. Phần suy luận của mô hình dùng chung ngân sách này và bị giới hạn ở 32 token; đây là trần chứ không phải tắt suy luận, được chốt trước khi chạy chính thức. Mỗi ô (hệ, kịch bản) được sinh một lần. Vì nhiệt độ sinh khác không, kết quả của một lần sinh không tất định. Khi một lượt nộp của hệ đề xuất bị từ chối, hệ viết lại sản phẩm đó một lần bằng giải mã có ràng buộc (constrained decoding) theo JSON Schema của sản phẩm. Đây là cơ chế sẵn có của vLLM [21], và cấu hình này giống nhau ở mọi biến thể của hệ. Sáu tác tử của benchmark chạy nguyên mã gốc, không có lượt viết lại này. Trung bình mỗi kịch bản có 3.4 lượt viết lại, trong đó 2.2 lượt vẫn không qua validator. Hai lượt sinh của EduPlanner lỗi do mất kết nối tới máy chủ mô hình. Một kịch bản có tệp đầu vào sai tên trường, và tệp được sửa theo bản gốc của benchmark. Các ô này được sinh lại với cùng cấu hình trước khi chấm. Hệ đề xuất được sinh riêng ở mỗi thí nghiệm, nên số liệu của nó ở Bảng I và Bảng III khác nhau đôi chút.

2) Thí nghiệm 1 – so sánh với các hệ của benchmark: AlignmentGraph-ISD được so sánh với sáu tác tử của ISD-Agent-Bench trên cùng 30 kịch bản: EduPlanner [3], Baseline (sinh một lượt), React-ADDIE (kết hợp ADDIE với kiểu suy luận ReAct [15]), ADDIE-Agent, Dick-Carey-Agent và RPISD-Agent. Tên tác tử theo bài báo gốc; prompt của React-ADDIE được dịch sang tiếng Anh, không đổi phương pháp.

3) Thí nghiệm 2 – phân tích thành phần: Để tách vai trò của hai lựa chọn thiết kế, chúng tôi dùng thiết kế thực nghiệm giai thừa 2×2. Trục *phân rã* so sánh sáu tác tử theo vai (multi) với một tác tử đơn giữ một ngữ cảnh chung qua cả sáu giai đoạn (single). Trục *trạng thái* so sánh đồ thị căn chỉnh (graph) với một blackboard dạng văn bản (prose). Trong biến thể prose, mỗi giai đoạn lưu nguyên văn sản phẩm và giai đoạn sau đọc lại toàn văn. Mỗi trục thay đổi đồng thời một nhóm cơ chế. Trục phân rã thay đổi cùng lúc ranh giới ngữ cảnh, số vai, tầng Developer, việc chia và giao lại nhóm việc, và thời điểm sửa. Trục trạng thái thay đổi toàn bộ cơ chế căn chỉnh: đồ thị, công cụ đọc trạng thái, định tuyến vi phạm và kiểm toán. Vì vậy, kết quả được diễn giải cho cả nhóm cơ chế của từng trục, không quy cho một thành phần riêng lẻ.

4) Điểm LLM judge: Điểm ADDIE (0–100) đánh giá sản phẩm theo 33 tiêu chí con, gộp thành năm pha. Điểm Trajectory đánh giá quá trình gọi công cụ. Điểm tổng hợp là

$$\text{Total} = 0.7 \cdot \text{ADDIE} + 0.3 \cdot \text{Trajectory}. \tag{4}$$

Ba điểm được báo cáo song song. Chúng tôi diễn giải điểm ADDIE trước vì nó đo chất lượng nội dung thiết kế. Ba LLM judge của ba hãng khác nhau (GPT-6 Luna, Gemini 3.1 Flash-Lite, DeepSeek-V4.1-Flash) chấm mỗi đầu ra ở chế độ tắt suy luận. Điểm cuối cùng là trung vị của ba điểm. Không hãng nào trùng với hãng của mô hình tác tử. GPT-6 Luna không nhận tham số nhiệt độ nên không tất định. Bộ chấm của benchmark chỉ đưa cho LLM judge 20 lời gọi công cụ đầu tiên. Do đó, hệ phân rã chịu bất lợi do cách chấm ở điểm Trajectory.

5) Tín hiệu căn chỉnh: Vì LLM judge chấm từng pha riêng rẽ, chúng tôi đo thêm sáu tín hiệu liên quan đến căn chỉnh kiến tạo trên chính đầu ra mà không dùng LLM. Họ A đo mức tương ứng văn bản trên ba cạnh của tam giác: mục tiêu–đánh giá (OA), mục tiêu–hoạt động (OT) và hoạt động–đánh giá (TA), trong đó T chỉ hoạt động dạy–học. Với mỗi phần tử nguồn, lấy cosine lớn nhất với các phần tử đích và cắt giá trị âm về 0; tín hiệu là trung bình các giá trị này (rectified cosine trên $[0, 1]$). Phép đo không dùng ngưỡng ghép cặp. Văn bản được nhúng bằng bge-m3 [22]. Họ B đo mức nhận thức theo thang phân loại Bloom sửa đổi [19]. Cg là tỉ lệ mục tiêu mà câu hỏi đánh giá gần nhất với nó (theo cosine, không ngưỡng) có mức Bloom không thấp hơn mức của mục tiêu. Po là chỉ số Porter [23] $1 - \frac{1}{2}\sum_k |x_k - y_k|$, với x_k, y_k là tỉ lệ phần tử của hai phía rơi vào ô (chủ đề, mức Bloom) thứ k, trung bình trên ba cạnh của họ A. Wb là tính nhất quán mức nhận thức theo Webb [24], xét từ phía từng câu hỏi: tỉ lệ câu hỏi có mức Bloom không thấp hơn mức của mục tiêu gần nó nhất. Cg và Wb ghép cặp bằng cosine, còn Po gán chủ đề bằng cosine, nên họ B không hoàn toàn độc lập với họ A. Mức Bloom được gán bằng một bộ phân loại BERT [25] tinh chỉnh trên dữ liệu mục tiêu học tập [26] và câu hỏi thi [27] do chuyên gia gán nhãn ($\kappa = 0.90$ trên 4219 mẫu giữ lại). Tín hiệu bằng 0 khi hệ không sinh ra tập phần tử tương ứng. Quy trình chấm không dùng LLM và không có thành phần ngẫu nhiên. Kết quả tái lập được, sai khác chỉ ở mức nhiễu dấu phẩy động, nhờ cố định phiên bản encoder và lưu bộ đệm (cache) embedding. Các tín hiệu này chỉ phản ánh một số khía cạnh đo được của căn chỉnh kiến tạo.

6) Thước đo quá trình và thống kê: Với Thí nghiệm 2, chúng tôi tính tỉ lệ mục tiêu có đủ ba cạnh C_2, C_3, C_4 theo (2) trên đầu ra của cả bốn biến thể. Thước đo này tính được trên cả đồ thị lẫn blackboard. Đây là mức tuân thủ cấu trúc, không phải giá trị sư phạm. Các bảng ghi trung bình qua 30 kịch

Bảng I
THÍ NGHIỆM 1: ĐIỂM LLM JUDGE (TRUNG BÌNH ± ĐỘ LỆCH CHUẨN QUA 30 KỊCH BẢN) VÀ TOKEN MỖI KỊCH BẢN

Hệ	ADDIE ↑	Trajectory ↑	Total ↑	Token (k) ↓
AlignmentGraph-ISD	59.0 ± 2.8	69.7 ± 5.9	62.2 ± 2.3	282
EduPlanner	$30.0 \pm 19.8^*$	53.0 ± 32.7	$36.9 \pm 23.2^*$	70
Baseline	$43.4 \pm 17.7^*$	69.2 ± 19.0	$51.1 \pm 16.6^*$	10
React-ADDIE	$\mathbf{59.1 \pm 6.7}$	71.5 ± 9.5	$\mathbf{62.8 \pm 4.9}$	15
ADDIE-Agent	$48.5 \pm 3.6^*$	$\mathbf{81.5 \pm 3.0}^*$	$58.4 \pm 2.7^*$	23
Dick-Carey-Agent	58.0 ± 3.0	72.6 ± 5.6	62.4 ± 3.1	26
RPISD-Agent	58.4 ± 2.5	69.9 ± 3.3	61.8 ± 1.9	61

* khác AlignmentGraph-ISD, Wilcoxon theo cặp, Holm trong từng điểm, $p < 0.05$. Kịch bản không có đầu ra chấm được, tính 0 điểm: EduPlanner 8, Baseline 2.

Bảng II
THÍ NGHIỆM 1: TÍN HIỆU CĂN CHỈNH (TRUNG BÌNH QUA 30 KỊCH BẢN)

	Họ A: văn bản			Họ B: Bloom		
Hệ	OA ↑	OT ↑	TA ↑	Cg ↑	Po ↑	Wb ↑
AlignmentGraph-ISD	**0.76**	**0.75**	**0.71**	0.75	**0.42**	0.66
EduPlanner	0.43*	0.40*	0.35*	0.45*	0.17*	0.40*
Baseline	0.45*	0.33*	0.29*	0.57	0.13*	0.45*
React-ADDIE	0.69*	0.63*	0.57*	0.68	0.22*	0.52*
ADDIE-Agent	0.69*	0.64*	0.52*	0.69	0.30*	0.58
Dick-Carey-Agent	0.66*	0.63*	0.62*	**0.78**	0.34*	**0.69**
RPISD-Agent	0.64*	0.65*	0.52*	0.53*	0.28*	0.50*

* khác AlignmentGraph-ISD, Wilcoxon theo cặp, Holm trong từng tín hiệu, $p < 0.05$.

bản; Bảng I và cột ADDIE của Bảng III ghi thêm độ lệch chuẩn. Ở Thí nghiệm 1, hệ đề xuất được so sánh với từng hệ còn lại bằng kiểm định Wilcoxon theo cặp kịch bản. Giá trị p được hiệu chỉnh Holm trong từng điểm số hoặc từng tín hiệu. Ở Thí nghiệm 2, hai kiểm định được định trước, ghi trong cấu hình đã cố định trước khi chạy chính thức, với giả thuyết multi cao hơn single về điểm ADDIE và graph cao hơn prose về tỉ lệ mục tiêu khép kín tam giác. Thước đo của trục trạng thái được chốt sau khi xem dữ liệu của giai đoạn hoàn thiện, trước khi chạy chính thức, vì LLM judge chấm từng pha riêng rẽ nên không thấy liên kết giữa các pha. Hai kiểm định này thuộc cùng một nhóm hiệu chỉnh Holm. Ở cả hai thí nghiệm, hệ không sinh ra đầu ra chấm được ở một kịch bản thì nhận 0 điểm ở kịch bản đó. Vì chênh lệch theo cặp thường có hạng bằng nhau hoặc bằng 0, giá trị p của Wilcoxon được tính chính xác theo phân phối hoán vị có điều kiện. Khoảng tin cậy 95% được ước lượng bằng bootstrap.

B. Kết quả

1) Thí nghiệm 1: Bảng I trình bày điểm LLM judge. Về điểm ADDIE, AlignmentGraph-ISD (59.0) không khác biệt có ý nghĩa với React-ADDIE (59.1, $p = 0.730$), Dick-Carey-Agent (58.0) và RPISD-Agent (58.4). Hệ đề xuất cao hơn ADDIE-Agent 10.5 điểm, Baseline 15.6 điểm và EduPlanner 28.9 điểm ($p < 0.001$ ở cả ba so sánh). Một phần chênh lệch với hai hệ sau đến từ các kịch bản không có đầu ra chấm được (chú thích Bảng I). Baseline thất bại vì đầu ra chạm trần 8192 token, còn EduPlanner thất bại vì đầu ra không khớp lược đồ (schema) do chính nó quy định. Về điểm Trajectory, ADDIE-Agent đạt cao nhất (81.5) và cao hơn có ý nghĩa so với hệ đề xuất ($p < 0.001$). Về điểm Total, hệ đề xuất không khác biệt có ý nghĩa với React-ADDIE, Dick-Carey-Agent và RPISD-Agent.

Bảng II trình bày sáu tín hiệu căn chỉnh. Tuy điểm ADDIE không tách được hệ đề xuất khỏi React-ADDIE, song AlignmentGraph-ISD có ba tín hiệu họ A cao nhất (OA 0.76, OT 0.75, TA 0.71) và chỉ số Porter cao nhất (0.42). Các khác biệt này có ý nghĩa với cả sáu tác tử. Với Cg và Wb, Dick-Carey-Agent đạt giá trị cao hơn hệ đề xuất nhưng khác biệt không có ý nghĩa (Cg $p = 1.000$, Wb $p = 0.666$).

AlignmentGraph-ISD dùng trung bình 282k token cho mỗi kịch bản, khoảng 18.3 lần React-ADDIE. Hệ có chi phí tính toán cao hơn đáng kể so với các hệ dạng quy trình gọn nhẹ. Chúng tôi báo cáo chi phí này bên cạnh các tín hiệu căn chỉnh, khả năng truy vết và khả năng kiểm toán, mà không diễn giải rằng hệ hiệu quả hơn về mặt tính toán.

2) Thí nghiệm 2: Bảng III trình bày bốn biến thể. Kiểm định định trước cho trục phân rã ủng hộ giả thuyết: biến thể multi cao hơn single 4.9 điểm ADDIE (khoảng tin cậy 95% [3.9; 5.8], $p < 0.001$). Tỉ lệ mục tiêu khép kín tam giác cũng tăng từ 67–69% ở biến thể single lên 86–87% ở biến thể multi. Không giai đoạn nào của hai biến thể single bị trần lượt cắt (multi-graph: 1.1%), nên khác biệt này không đến từ việc single hết lượt. Kiểm định định trước cho trục trạng thái không phát hiện khác biệt: chênh lệch tỉ lệ khép kín của graph so với prose là -1 điểm phần trăm (khoảng tin cậy 95% $[-12; 8]$, $p = 0.925$). Khoảng tin cậy này rộng: với 30 kịch bản, thí nghiệm không loại trừ được chênh lệch đến 12 điểm phần trăm về phía prose hay 8 điểm về phía graph. Ở biến thể graph, tầng sửa cấu trúc chỉ nối thêm cạnh C_4 cho 1.5% hoạt động (multi) và 5.2% (single); các cạnh C_2 và C_3 đều xuất phát từ tham chiếu do tác tử viết. Biến thể single tốn nhiều token hơn multi (428k so với 278k ở biến thể graph).

Bảng III
THÍ NGHIỆM 2: PHÂN RÃ × TRẠNG THÁI (30 KỊCH BẢN)

Biến thể	ADDIE ↑	Total ↑	Khép kín (%) ↑	Token (k) ↓
multi, graph (đề xuất)	58.2 ± 2.6	62.4	86	278
multi, prose	$\mathbf{58.6 \pm 2.6}$	**64.1**	**87**	255
single, graph	53.1 ± 3.7	56.5	67	428
single, prose	53.9 ± 3.0	56.7	69	414

Khép kín: tỉ lệ mục tiêu có đủ ba cạnh C_2–C_4 trong đầu ra.

C. Thảo luận

(1) Cạnh tranh về điểm LLM judge. Với mô hình 2B, điểm ADDIE của hệ đề xuất không khác biệt có ý nghĩa với các tác tử mạnh nhất của benchmark. Độ lệch chuẩn qua kịch bản của hệ (2.8) ngang Dick-Carey-Agent (3.0) và RPISD-Agent (2.5), thấp hơn React-ADDIE (6.7), tức điểm ADDIE ít dao động hơn giữa các kịch bản.

(2) Tín hiệu họ A tách hệ đề xuất khỏi các tác tử mạnh, điểm ADDIE thì không. Có hai cách đọc kết quả này. Cách thứ nhất: LLM judge chấm từng pha ADDIE riêng rẽ nên không thấy liên kết giữa các pha, đúng là lý do cần đo thêm tín hiệu căn chỉnh. Cách thứ hai: khung điều phối đã kiểm tra, ngay lúc nộp, một số ràng buộc mà các tín hiệu này đo,

nên tín hiệu cao một phần phản ánh việc hệ tuân thủ ràng buộc của chính nó. Bằng chứng độc lập cần đến đánh giá của chuyên gia.

(3) Phân rã đa tác tử có tác dụng rõ với Qwen3.5-2B. Trục này gồm các thay đổi nêu ở phần thiết lập Thí nghiệm 2. Với mô hình 2B, cả điểm ADDIE và tỉ lệ khép kín tam giác đều tăng, đồng thời số token giảm.

(4) Không phát hiện khác biệt giữa đồ thị căn chỉnh và blackboard dạng văn bản. Biến thể prose không khác biệt có ý nghĩa so với graph về tỉ lệ khép kín, và điểm ADDIE của hai biến thể gần nhau. Về số, multi-prose nhỉnh hơn multi-graph ở cả ba cột của Bảng III và dùng ít token hơn. Trong thực nghiệm này, khác biệt của biến thể graph là hồ sơ kiểm toán mà biến thể prose không có.

Hạn chế. Thực nghiệm dùng một nấc mô hình, 30 kịch bản và một lần sinh cho mỗi ô. Điểm LLM judge có thiên lệch. Chúng tôi dùng ba LLM judge thay cho cặp LLM judge mặc định của benchmark (GPT-4o-mini và Gemini 2.5 Flash-Lite), vì trong giai đoạn hoàn thiện cặp này cho điểm ít phân tán giữa các kịch bản, và GPT-4o-mini thuộc nhóm chấm kém nhất trên đầu ra dài, trong khi DeepSeek-V4-Flash (bản trước của V4.1-Flash) thuộc nhóm tốt nhất [28]. Các LLM judge này lệch nhau đáng kể về mức điểm tuyệt đối (độ lệch chuẩn giữa ba LLM judge trung bình 8.7 điểm ADDIE), và thứ hạng giữa hệ đề xuất và React-ADDIE thay đổi theo từng LLM judge. Chúng tôi đã kiểm tra rằng cả ba LLM judge nhận đủ các đầu ra dài và không chấm nhầm nội dung có thật là bị thiếu. Bằng chứng độc lập về chất lượng thiết kế cần đến đánh giá của chuyên gia thiết kế giảng dạy. Kết quả được quan sát trên Qwen3.5-2B và chưa được kiểm chứng trên các cỡ mô hình và các họ mô hình khác.

V. KẾT LUẬN

Bài báo đã trình bày AlignmentGraph-ISD, một hệ đa tác tử phân rã theo vai cho thiết kế giảng dạy. Trong hệ này, các tác tử dùng chung một đồ thị căn chỉnh làm trạng thái trung tâm. Trên 30 kịch bản với Qwen3.5-2B, tuy điểm LLM judge của hệ không khác biệt có ý nghĩa với tác tử mạnh nhất của benchmark, song các tín hiệu tương ứng văn bản của hệ cao hơn cả sáu hệ đối chứng. Thí nghiệm phân tích thành phần cho thấy việc phân rã thành nhiều tác tử theo vai nâng điểm ADDIE so với một tác tử duy nhất. Trong khi đó, đồ thị căn chỉnh không cho thấy khác biệt có ý nghĩa so với blackboard dạng văn bản, mà chủ yếu bổ sung hồ sơ kiểm toán. Hướng phát triển gồm đánh giá trên nhiều cỡ mô hình, lặp lại nhiều lần sinh cho mỗi kịch bản và lấy đánh giá của chuyên gia thiết kế giảng dạy trên đồ thị và sổ vi phạm mà hệ xuất ra.

TÀI LIỆU THAM KHẢO

[1] R. M. Branch, *Instructional Design: The ADDIE Approach*. New York, NY: Springer, 2009.

[2] X. Zeng, Y. Zheng, S. Huang *et al.*, "COMA: A collaborative multi-role agent framework for automated lesson plan generation," in *Proc. ACM Web Conf. 2026 (WWW '26)*, 2026, pp. 9745–9756.

[3] X. Zhang, C. Zhang, J. Sun, J. Xiao, Y. Yang, and Y. Luo, "EduPlanner: LLM-based multi-agent systems for customized and intelligent instructional design," *IEEE Transactions on Learning Technologies*, vol. 18, pp. 416–427, 2025.

[4] H. Yao, W. Xu, J. Turnau, N. Kellam, and H. Wei, "Instructional agents: Reducing teaching faculty workload through multi-agent instructional design," in *Proc. EACL 2026 (Long Papers)*, 2026, pp. 4087–4109.

[5] Y. Jeon, S. Kim, H. Son, S. Lee, Y. Jeong, and U. Lee, "ISD-Agent-Bench: A comprehensive benchmark for evaluating LLM-based instructional design agents," arXiv preprint arXiv:2602.10620, 2026.

[6] J. Robert and M. McCormack, "2025 EDUCAUSE AI landscape study: Into the digital AI divide," EDUCAUSE, Tech. Rep., 2025.

[7] L. Yan, L. Sha, L. Zhao *et al.*, "Practical and ethical challenges of large language models in education: A systematic scoping review," *British Journal of Educational Technology*, vol. 55, no. 1, pp. 90–112, 2024.

[8] C. K. Y. Chan, W. Dai, K. Cao, A. T. Y. Poon, and T. Colloton, "Bigger isn't always better: Choosing the right size large language model for locally hosted school settings," *Applied Sciences*, vol. 16, no. 11, p. 5268, 2026.

[9] K. Katharakis, S. Rossi, and R. R. Mukkamala, "Small language models for curriculum-based guidance," arXiv preprint arXiv:2510.02347, 2025.

[10] W. Shen, C. Li, H. Chen *et al.*, "Small LLMs are weak tool learners: A multi-LLM agent," in *Proc. EMNLP 2024*, 2024, pp. 16 658–16 680.

[11] M. Kang, J. Jeong, S. Lee, J. Cho, and S. J. Hwang, "Distilling LLM agent into small models with retrieval and code tools," in *Advances in Neural Information Processing Systems*, vol. 38, 2025.

[12] Y.-e. Cho, "It's not the capability: Harness sensitivity is non-monotone across LLM agent tiers," arXiv preprint arXiv:2605.26731, 2026.

[13] J. Biggs, "Enhancing teaching through constructive alignment," *Higher Education*, vol. 32, no. 3, pp. 347–364, 1996.

[14] J. Ye, Y. Wang, Y. Huang *et al.*, "Justice or prejudice? quantifying biases in LLM-as-a-judge," in *Proc. ICLR 2025*, 2025.

[15] S. Yao, J. Zhao, D. Yu *et al.*, "ReAct: Synergizing reasoning and acting in language models," in *Proc. ICLR 2023*, 2023.

[16] S. Hong, M. Zhuge, J. Chen *et al.*, "MetaGPT: Meta programming for a multi-agent collaborative framework," in *Proc. ICLR 2024*, 2024.

[17] T. Guo, X. Chen, Y. Wang *et al.*, "Large language model based multi-agents: A survey of progress and challenges," in *Proc. IJCAI-24*, 2024, pp. 8048–8057.

[18] E. Pereira, S. Nsair, L. Radin Pereira, and K. Grant, "Constructive alignment in a graduate-level project management course: an innovative framework using large language models," *International Journal of Educational Technology in Higher Education*, vol. 21, p. 25, 2024.

[19] L. W. Anderson and D. R. Krathwohl, *A Taxonomy for Learning, Teaching, and Assessing: A Revision of Bloom's Taxonomy of Educational Objectives*. New York, NY: Longman, 2001.

[20] G. Wiggins and J. McTighe, *Understanding by Design*, 2nd ed. Alexandria, VA: Association for Supervision and Curriculum Development (ASCD), 2005.

[21] W. Kwon, Z. Li, S. Zhuang *et al.*, "Efficient memory management for large language model serving with PagedAttention," in *Proc. SOSP '23*, 2023.

[22] J. Chen, S. Xiao, P. Zhang, K. Luo, D. Lian, and Z. Liu, "M3-embedding: Multi-linguality, multi-functionality, multi-granularity text embeddings through self-knowledge distillation," in *Findings of ACL 2024*, 2024, pp. 2318–2335.

[23] A. C. Porter, "Measuring the content of instruction: Uses in research and practice," *Educational Researcher*, vol. 31, no. 7, pp. 3–14, 2002.

[24] N. L. Webb, "Criteria for alignment of expectations and assessments in mathematics and science education," Nat. Inst. Sci. Educ., Univ. Wisconsin–Madison, Research Monograph 6, 1997.

[25] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of deep bidirectional transformers for language understanding," in *Proc. NAACL-HLT 2019*, 2019, pp. 4171–4186.

[26] Y. Li, M. Rakovic, B. X. Poh, D. Gašević, and G. Chen, "Automatic classification of learning objectives based on Bloom's taxonomy," in *Proc. EDM 2022*, 2022.

[27] A. Faraji, M. Molavi, Z. Rasoulkhani, M. Tavakoli, and G. Kismihók, "Cross-dataset Bloom question classification: Supervised models and prompted LLMs," in *Proc. AIED 2026*, ser. LNCS, 2026, pp. 198–207.

[28] J. Chen, Y. Dong, H. Li, W. Su, Y. Zhou, M. Zhang, Y. Liu, and Q. Ai, "Benchmarking LLM-as-a-judge for long-form output evaluation," arXiv preprint arXiv:2606.01629, 2026.